

LAPORAN TEKNIS KOMPREHENSIF
Data Science Pipeline SYNAR (Safety UV Navigator)
Coding Camp Capstone Project 2026

Daftar Isi

Daftar Isi	ii
BAB 1 PROBLEM DISCOVERY	2
1.1 Latar Belakang	2
1.2 Problem Statement	2
1.3 Tujuan Project (Bagian DS)	2
BAB 2 DATA COLLECTION	3
2.1 Sumber Data	3
2.2 Spesifikasi Data	3
2.3 Parameter yang Dikumpulkan	3
2.4 Alasan Pemilihan 3 Lokasi	3
BAB 3 GATHERING & ASSESSING	4
3.1 Struktur Data Mentah	4
3.2 Hasil 8 Pemeriksaan Assessing	4
BAB 4 DATA CLEANING	5
4.1 Langkah-Langkah Cleaning	5
4.2 Hasil Cleaning	5
BAB 5 FEATURE ENGINEERING	6
5.1 Fitur Baru yang Dibuat	6
5.2 Target Model: DURASI_AMAN_MENIT	6
5.3 Statistik Dataset Setelah Feature Engineering	6
5.4 Split Dataset: Time-based 80/10/10	7
BAB 6 VALIDASI DATA LEAKAGE	8
6.1 Definisi	8
6.2 Fitur Training yang Ditetapkan	8
6.3 Hasil Validasi	8
BAB 7 A/B TESTING	9
7.1 Hipotesis	9
7.2 Hasil	9
7.3 Interpretasi: Statistical vs Practical Significance	9
BAB 8 DELIVERABLES	10
8.1 File Output yang Dihasilkan	10
BAB 9 KESIMPULAN DAN LIMITASI	11

9.1 Kesimpulan.....	11
9.2 Limitasi.....	11
9.3 Rekomendasi Pengembangan.....	11

BAB 1

PROBLEM DISCOVERY

1.1 Latar Belakang

Indonesia merupakan negara tropis yang terletak di garis khatulistiwa, menjadikannya salah satu wilayah dengan intensitas radiasi ultraviolet (UV) tertinggi di dunia. Paparan sinar UV yang berlebihan dapat menyebabkan berbagai dampak negatif bagi kesehatan kulit, mulai dari sunburn ringan, penuaan dini, hingga risiko kanker kulit jangka panjang. Di sisi lain, paparan sinar matahari dalam dosis yang tepat justru bermanfaat bagi tubuh, terutama untuk produksi vitamin D.

Aktivitas berjemur di pantai semakin populer di kalangan wisatawan domestik maupun mancanegara yang mengunjungi destinasi pantai Indonesia seperti Bali, Lombok, dan Raja Ampat. Namun, sebagian besar masyarakat tidak memiliki pemahaman yang memadai mengenai waktu yang aman untuk berjemur berdasarkan kondisi UV dan tipe kulit mereka. Ketidadaan sistem yang dapat memprediksi keamanan berjemur secara personal dan real-time menjadi permasalahan utama yang ingin diselesaikan oleh project SYNAR.

1.2 Problem Statement

Bagaimana memprediksi durasi aman berjemur secara real-time berdasarkan kombinasi kondisi cuaca (UV Index, suhu, kelembapan, angin) dan tipe kulit pengguna menggunakan data historis NASA POWER?

1.3 Tujuan Project (Bagian DS)

- Membangun pipeline data science end-to-end dari crawling hingga model-ready dataset
- Menghasilkan target DURASI_AMAN_MENIT berbasis formula SED (Standard Erythematous Dose)
- Memvalidasi kualitas data dan memastikan tidak ada data leakage
- Menyediakan dataset bersih yang siap digunakan AI Engineer untuk training model
- Mendokumentasikan seluruh proses dalam notebook yang reproducible

BAB 2

DATA COLLECTION

2.1 Sumber Data

Data cuaca dan UV diperoleh dari NASA POWER Data Access Viewer (DAV), platform penyedia data meteorologi dan energi surya berbasis satelit milik NASA. NASA POWER dipilih karena menyediakan data historis dengan resolusi temporal per jam (hourly) yang konsisten, akurat, dan gratis untuk keperluan riset.

2.2 Spesifikasi Data

- **Periode:** 2020 – 2025 (6 tahun)
- **Resolusi:** Hourly (per jam, 24 data per hari)
- **Lokasi 1:** Pantai Sanur, Bali (-8.72°S, 115.26°E) — representasi Indonesia Tengah
- **Lokasi 2:** Pantai Senggigi, Lombok (-8.50°S, 116.03°E) — representasi Indonesia Tengah-Timur
- **Lokasi 3:** Waisai, Raja Ampat (-0.44°S, 130.85°E) — representasi Indonesia Timur
- **Total baris:** ~157.824 baris (setelah digabungkan)

2.3 Parameter yang Dikumpulkan

Parameter	Nama Lengkap	Satuan
ALLSKY_SFC_UV_INDEX	All Sky Surface UV Index	$\text{W m}^{-2} \times 40$
ALLSKY_SFC_UVA	All Sky Surface UVA Irradiance	MJ/hr
ALLSKY_SFC_UVB	All Sky Surface UVB Irradiance	MJ/hr
T2M	Temperature at 2 Meters	°C
WS2M	Wind Speed at 2 Meters	m/s
RH2M	Relative Humidity at 2 Meters	%

2.4 Alasan Pemilihan 3 Lokasi

Ketiga lokasi dipilih sebagai representasi geografis Indonesia dari tengah ke timur. Model tidak belajar dari lokasi spesifik, melainkan dari pola hubungan antar variabel cuaca. Hal ini memungkinkan generalisasi ke wilayah lain di Indonesia melalui NASA POWER API real-time saat inference. Saat user memilih lokasi lain di aplikasi, data cuaca real-time untuk koordinat tersebut diambil langsung dari NASA POWER API oleh backend.

BAB 3

GATHERING & ASSESSING

3.1 Struktur Data Mentah

Data mentah hasil crawling disimpan dalam file `raw_data_gabungan.csv` dengan total 157.824 baris. Setiap baris merepresentasikan satu pengukuran per jam untuk satu lokasi.

3.2 Hasil 8 Pemeriksaan Assessing

No	Pemeriksaan	Hasil	Kesimpulan
1	Shape dataset	157.824 baris, 7 kolom	Normal
2	Tipe data	YEAR/MO/DY/HR: int, UV/cuaca: float	Sesuai ekspektasi
3	Missing value (NaN)	0 nilai NaN	Tidak ada missing
4	Duplikat	0 baris duplikat	Tidak ada duplikat
5	Nilai -999 (NASA code)	UVA: 72, UVB: 72, UV_INDEX: 72	Perlu ditangani
6	Statistik deskriptif	UV max: 15.95, T2M mean: 27.64°C	Wajar untuk tropis
7	Data per lokasi	~52.608 baris/lokasi	Seimbang
8	Rentang tahun	2020–2025 di semua lokasi	Konsisten

Temuan utama: Data relatif bersih dengan satu masalah utama yaitu nilai -999 yang merupakan kode NASA untuk data tidak tersedia. Nilai ini terkonsentrasi pada kolom UVA, UVB, dan UV_INDEX (masing-masing 72 nilai dari 157.824 baris = 0.05%).

BAB 4

DATA CLEANING

4.1 Langkah-Langkah Cleaning

Step 1: Pembuatan Kolom DATETIME Kolom YEAR, MO, DY, dan HR digabungkan menjadi satu kolom DATETIME bertipe datetime64. Tujuannya adalah memudahkan analisis time series dan memastikan urutan temporal data terjaga.

Step 2: Penggantian Nilai -999 dengan NaN Nilai -999 merupakan kode standar NASA POWER untuk data yang tidak tersedia. Nilai ini diganti dengan NaN terlebih dahulu sebelum imputasi, agar tidak mempengaruhi perhitungan statistik.

Step 3: Imputasi Missing Value Missing value diisi menggunakan median per lokasi per jam (groupby LOKASI dan HR). Alasan pemilihan metode ini:

- Median lebih robust terhadap outlier dibanding mean
- Imputasi per jam mempertahankan pola sirkadian UV harian
- UV jam 06:00 sangat berbeda dari jam 12:00, sehingga imputasi global tidak tepat

Step 4: Deteksi dan Penanganan Outlier Outlier dideteksi menggunakan Z-score dengan threshold > 4 . Threshold dipilih lebih longgar dari standar umum (3) karena data cuaca tropis memang memiliki variasi yang lebih ekstrem secara alami. Outlier yang terdeteksi diganti dengan median per lokasi per jam.

Step 5: Validasi Akhir Verifikasi tidak ada NaN tersisa, tidak ada duplikat baru, dan statistik deskriptif berada dalam rentang wajar.

4.2 Hasil Cleaning

Metrik	Sebelum	Sesudah
Missing value	216 nilai (-999)	0
Duplikat	0	0
Outlier $Z > 4$	Ada di beberapa kolom	Sudah diimputasi
Output file	—	clean_data.csv

BAB 5

FEATURE ENGINEERING

5.1 Fitur Baru yang Dibuat

Fitur	Tipe	Cara Pembuatan
DATETIME	datetime	Gabungan YEAR+MO+DY+HR
JAM_KATEGORI	category	pd.cut HR → Dini Hari/Pagi/Siang/Sore/Malam
IS_DAYTIME	int (0/1)	HR.between(6,17)
BULAN	int	Copy dari MO
MUSIM	str	Mapping bulan → Hujan/Kemarau/Peralihan
DURASI_AMAN_MENIT	float	TARGET MODEL — Formula SED
LABEL_AMAN	int (0/1)	Referensi — diturunkan dari $DURASI_AMAN_MENIT \geq 10$ menit

5.2 Target Model: DURASI_AMAN_MENIT

Berdasarkan review AI Engineer, target model diubah dari LABEL_AMAN (binary 0/1) menjadi DURASI_AMAN_MENIT (float, 0–120 menit). Model yang digunakan adalah Random Forest Regressor, bukan klasifikasi.

Formula SED (Standard Erythemat Dose):

- $MED_BASELINE = 4.5 \text{ J/m}^2$ (Fitzpatrick Type III — baseline)
- $DURASI = MED_BASELINE / (UV_INDEX \times 0.0025 \times 60)$
- Cap maksimal: 120 menit
- Threshold aman: $DURASI \geq 10$ menit → Aman (1)

Catatan: Penyesuaian per tipe kulit (Fitzpatrick) dilakukan di serving API oleh AI Engineer, bukan di dalam model.

5.3 Statistik Dataset Setelah Feature Engineering

Variabel	Mean	Std	Min	Max
ALLSKY_SFC_UV_INDEX	4.62	3.89	0.00	15.95
T2M (°C)	27.64	1.82	20.31	34.73
RH2M (%)	76.49	9.81	37.84	100.00
WS2M (m/s)	1.91	1.14	0.01	8.62
DURASI_AMAN_MENIT	31.95	43.68	1.90	120.00

- Total baris (setelah filter jam 06–17): 78.912 baris
- Total kolom: 18 kolom
- Proporsi Aman (durasi ≥ 10 menit): 43.2%

- Proporsi Tidak Aman (durasi < 10 menit): 56.8%

5.4 Split Dataset: Time-based 80/10/10

Split dilakukan berdasarkan urutan waktu, bukan random shuffle. Penggunaan random shuffle pada data time series dapat menyebabkan data leakage karena data dari masa depan bisa masuk ke training set.

Split	Proporsi	Jumlah Baris	Periode
Train	80%	~63.130	2020 – mid 2024
Validation	10%	~7.891	mid 2024 – late 2024
Test	10%	~7.891	late 2024 – 2025

BAB 6

VALIDASI DATA LEAKAGE

6.1 Definisi

Data leakage terjadi ketika informasi dari target ikut masuk ke dalam fitur training, sehingga model mendapat keuntungan yang tidak realistis saat training namun gagal saat production.

6.2 Fitur Training yang Ditetapkan

Fitur	Sumber	Korelasi vs Target
ALLSKY_SFC_UV_INDEX	NASA POWER	Tinggi negatif (~ -0.87)
ALLSKY_SFC_UVA	NASA POWER	Tinggi negatif (~ -0.83)
ALLSKY_SFC_UVB	NASA POWER	Tinggi negatif (~ -0.78)
T2M	NASA POWER	Sedang negatif (~ -0.35)
RH2M	NASA POWER	Sedang positif ($+0.42$)
WS2M	NASA POWER	Hampir nol (~ 0.00)
HR	NASA POWER	Rendah (~ -0.04)
BULAN	Feature Engineering	Sangat rendah (~ -0.02)

6.3 Hasil Validasi

- Tidak ada kolom target (DURASI_AMAN_MENIT atau LABEL_AMAN) yang masuk ke fitur training
- Semua korelasi fitur vs target berada di bawah threshold leakage 0.95
- Korelasi tinggi UV Index vs DURASI_AMAN_MENIT (~ -0.87) bukan leakage — wajar karena target memang dihitung dari UV Index

Catatan penting: Korelasi UV Index terhadap DURASI_AMAN_MENIT yang tinggi adalah hubungan kausal yang logis. UV tinggi menghasilkan durasi pendek. Ini bukan data leakage karena pada inference, model menerima UV Index sebagai input, bukan durasi-nya.

BAB 7

A/B TESTING

7.1 Hipotesis

- **H0:** Tidak ada perbedaan proporsi kondisi aman berjemur yang signifikan antar lokasi
- **H1:** Ada perbedaan proporsi kondisi aman berjemur yang signifikan antar lokasi
- **Metode:** Chi-square test | Tingkat signifikansi: $\alpha = 0.05$
- **Threshold aman:** DURASI_AMAN_MENIT ≥ 10 menit

7.2 Hasil

Lokasi	% Aman	Rata-rata Durasi	UV Index Rata-rata
Bali	42.7%	31.9 menit	4.67
Lombok	42.8%	31.5 menit	4.68
Raja Ampat	44.1%	32.4 menit	4.52
Chi-square	P-value	Keputusan	
12.55	0.0019	Tolak H0	

7.3 Interpretasi: Statistical vs Practical Significance

Meskipun hasil chi-square menunjukkan perbedaan signifikan secara statistik ($p = 0.0019 < 0.05$), perbedaan praktis antar lokasi hanya sekitar 1–2%. Hal ini terjadi karena ukuran dataset sangat besar (~78.912 baris), sehingga chi-square test sangat sensitif terhadap perbedaan kecil sekalipun.

Implikasi positif dari hasil ini: pola UV di ketiga lokasi relatif seragam, yang justru mendukung argumen bahwa model yang dilatih dari 3 lokasi dapat digeneralisasi ke wilayah Indonesia lainnya.

BAB 8

DELIVERABLES

8.1 File Output yang Dihasilkan

File	Format	Keterangan
raw_data_gabungan.csv	CSV	Data mentah 3 lokasi, ~157.824 baris
clean_data.csv	CSV	Data sudah dibersihkan + DATETIME
dataset_features.csv	CSV	78.912 baris, 18 kolom, siap training
train.csv	CSV	80% data training (~63.130 baris)
val.csv	CSV	10% data validasi (~7.891 baris)
test.csv	CSV	10% data test (~7.891 baris)
feature_spec.md	MD	Dokumentasi fitur, formula, split
data_dictionary.csv / .md	CSV/MD	Dokumentasi 18 kolom dataset
validasi_leakage.png	PNG	Grafik korelasi fitur vs target
ab_testing.png	PNG	Grafik A/B testing per lokasi
app.py	PY	Dashboard Streamlit interaktif
01_wrangling.ipynb	IPYNB	Notebook utama DS pipeline

BAB 9

KESIMPULAN DAN LIMITASI

9.1 Kesimpulan

1. Pipeline data science SYNAR berhasil diselesaikan dari tahap crawling hingga dataset siap training dalam 4 minggu kerja.
2. Data NASA POWER terbukti berkualitas tinggi dengan tingkat missing value hanya 0.05% dan tidak ada duplikat.
3. Formula SED berbasis Fitzpatrick Type III berhasil menghasilkan target DURASI_AMAN_MENIT yang valid secara ilmiah.
4. Tidak ditemukan data leakage pada seluruh fitur training berdasarkan pemeriksaan korelasi dan validasi manual.
5. A/B Testing menunjukkan pola UV relatif seragam antar 3 lokasi, mendukung kemampuan generalisasi model.
6. Split time-based 80/10/10 diterapkan untuk mencegah data leakage pada data time series.

9.2 Limitasi

- Hanya 3 lokasi pantai sebagai data training — belum ada representasi Indonesia Barat (Sumatera, Kalimantan)
- Data training berasal dari zona WITA/WIT — potensi perbedaan karakteristik cuaca dengan WIB perlu diteliti lebih lanjut
- Formula SED menggunakan Fitzpatrick Type III sebagai baseline — penyesuaian per tipe kulit dilakukan di serving API
- Variabel MUSIM memiliki korelasi rendah terhadap target karena Indonesia tidak memiliki 4 musim yang berbeda secara ekstrem

9.3 Rekomendasi Pengembangan

- Tambah data dari wilayah Indonesia Barat untuk meningkatkan representativitas model
- Eksplorasi walk-forward validation sebagai alternatif split 80/10/10
- Pertimbangkan penambahan fitur cloud cover dari NASA POWER untuk kondisi berawan
- Monitoring data drift secara berkala mengingat pola cuaca dapat berubah akibat perubahan iklim